UPN “VETERAN” JAWA TIMUR 2026

Komputasi Awan

DETEKSI UJARAN KEBENCIAN (CYBERBULLYING) PADA KOMENTAR MEDIA SOSIAL MENGGUNAKAN AWS S3 DAN SAGEMAKER

Kelompok 1

INTRODUCE

Muhammad Haikal Pasya Abdillah
240830100052

Muhammad Naufal Asruzzaman
240830100084

Yogi Dwi Arsanti
240830100020

LATAR BELAKANG

Perkembangan teknologi digital dan media sosial memudahkan komunikasi, tetapi juga memicu munculnya cyberbullying yang berdampak pada kondisi psikologis korban seperti stres, kecemasan, dan depresi. Untuk mengidentifikasi konten tersebut, diperlukan analisis data dalam skala besar. Oleh karena itu, penelitian ini memanfaatkan cloud computing (AWS) untuk mendukung proses pengolahan data secara efisien melalui penerapan analisis sentimen.

TUJUAN

Goal # 1

Mengumpulkan dan mempersiapkan dataset cyberbullying

Goal # 2

Menerapkan analisis sentimen untuk klasifikasi teks

Goal # 3

Mengimplementasikan cloud computing dalam pengolahan data

Goal # 4

Mengidentifikasi hasil dan pola sentimen pada data

ALUR

Briefly discuss the key dates for the project.

Data Collecting

- Mengambil Dataset
- Cleaning

Data Storage

- Upload Dataset (AWS S3)
- Penyimpanan: /raw dan /processed
- Mengaktifkan vesrioning

Data Processing

- Menggunakan EC2 /SageMaker
- Akses data dari S3 (boto3)
- Analisis sentimen / modeling

Data Accessing

- Mengambil hasil dari S3
- Menampilkan Visualisasi

DATASET

1 to 25 of 500 entries Filter

index	No	Sentimen
0	1	anjing poodle ku baru aja makan 3x sehari padahal badannya kecil banget
1	2	dasar goblok ngerjain tugas aja salah mulu mending lo keluar sekolah aja
2	3	babi
3	4	harga daging babi di pasar naik lagi bikin budget masak minggu ini bengkak
4	5	mati aja lo sekalian ga ada yang butuh lo di dunia ini
5	6	orang itu kelakuannya tolol banget masa password akun sendiri lupa
6	7	goblok
7	8	kelakuan lo itu kayak babi jorok dan ga tau malu sama sekali memalukan
8	9	film horor itu ceritanya tentang anjing yang bisa mati lalu hidup lagi seru banget plotnya
9	10	mukanya lo itu tolol banget pantesan ga ada yang mau berteman sama lo
10	11	anjing
11	12	teman ku pelihara anjing golden retriever lucu banget bulunya lebat
12	13	lo tuh goblok banget sih disuruh ngumpulin tugas tepat waktu aja ga bisa
13	14	tolol
14	15	babi hutan yang masuk ke kebun warga itu akhirnya berhasil ditangkap petugas
15	16	dasar anjing lo berani ngomong gitu ke gue
16	17	mati
17	18	orang itu ngomongnya kasar kayak anjing liar ga punya sopan santun sama sekali
18	19	lomba masak babi guling di bali itu penontonnya membludak tahun ini
19	20	lo mah goblok selamanya ga akan bisa maju hidupnya
20	21	teman sekelas gue itu tolol banget tapi dia sadar dan mau belajar keras
21	22	anjing tetangga gue nggak berhenti nggonggong dari tadi malem susah tidur
22	23	mati lo aja sana ga ada gunanya hidup
23	24	babi
24	25	si itu kelakuannya kayak babi ga punya malu norak abis

Show 25 per page

1 2 10 20

DATA COLLECTING

Pengumpulan data merupakan tahap awal dalam proses analisis sentimen. Pada penelitian ini, data dikumpulkan dari platform media sosial Twitter karena memiliki volume data yang besar serta banyak mengandung opini publik secara real-time. Data diperoleh melalui proses scraping dari platform Twitter. Proses scraping dilakukan dengan mengambil tweet berdasarkan kata kunci tertentu yang berkaitan dengan cyberbullying. Dalam penelitian ini, digunakan 5 kata kunci yang sering muncul dalam konteks cyberbullying, yaitu:

- Anjing
- Babi
- Goblok
- Mati
- Tolol

Kata kunci tersebut dipilih karena sering digunakan dalam ujaran kebencian atau penghinaan di media sosial. Jumlah data yang berhasil dikumpulkan adalah sebanyak 500 tweet. Data tersebut diambil secara acak berdasarkan kata kunci yang telah ditentukan, sehingga mencerminkan variasi penggunaan bahasa dalam konteks cyberbullying.Data yang dikumpulkan memiliki karakteristik sebagai berikut:

- Berupa teks (tweet)
- Mengandung kata kunci tertentu
- Bersifat tidak terstruktur
- Memiliki variasi panjang kalimat (pendek hingga panjang)
- Mengandung bahasa informal dan slang

PREPROCESSING DATA

Sebelum proses preprocessing dilakukan, load dataset sentimen terlebih dahulu dan menampilkannya

```
# Load Data
df = pd.read_csv('/content/sentimen_cyberbullying.csv')
df
```

	No	Sentimen
0	1	anjing poodle ku baru aja makan 3x sehari pada...
1	2	dasar goblok ngerjain tugas aja salah mulu men...
2	3	babi
3	4	harga daging babi di pasar naik lagi bikin bud...
4	5	mati aja lo sekalian ga ada yang butuh lo di d...
...	...	...
495	496	babi hutan menjadi salah satu hama pertanian p...
496	497	si tolol itu ga pernah mau ngaku salah padahal...
497	498	goblok banget lo tuh masuk rapat penting denga...
498	499	anjing
499	500	lo itu goblok parah sampe level mana pun lo ga...

500 rows × 2 columns

PREPROCESSING DATA

```python
# Cek null bawaan CSV
print("=== NULL VALUE ===")
print(df.isnull().sum())

# Tandai baris yang isinya cuma 1 kata (no context)
df['jumlah_kata'] = df['Sentimen'].astype(str).apply(lambda x: len(x.strip().split()))

print(f"\nData 1 kata (missing context) : {(df['jumlah_kata'] == 1).sum()}")
print(f"Data lebih dari 1 kata        : {(df['jumlah_kata'] > 1).sum()}")
df[df['jumlah_kata'] == 1]
```

```
=== NULL VALUE ===
No          0
Sentimen    0
dtype: int64

Data 1 kata (missing context) : 188
Data lebih dari 1 kata        : 312
```

Disini dilakukan pengecekan null, dan terlihat bahwa tidak ada null (0), tetapi dalam dataset terdapat beberapa data yang hanya terdapat 1 kata output yang akan dianggap sebagai null karena tidak ada konteksnya, dan terlihat jumlahnya ada 188

PREPROCESSING DATA

```python
# Cleaning Teks

def clean_text(text):
    text = str(text).lower()                # lowercase
    text = re.sub(r'[^\w\s]', '', text)     # hapus simbol & tanda baca
    text = re.sub(r'\s+', ' ', text)        # hapus spasi berlebih
    text = text.strip()
    return text

df['Sentimen_clean'] = df['Sentimen'].apply(clean_text)

print("Contoh hasil cleaning:")
df[['Sentimen', 'Sentimen_clean']]
```

Disini dilakukan cleaning yaitu membuat semua data menjadi lowercase, menghapus simbol dan tanda baca, dan hapus spasi berlebih agar mempermudah proses selanjutnya dan mengurangi kemungkinan error yang akan terjadi

PREPROCESSING DATA

```python
# Simpan dulu data 1 kata untuk catatan
df_missing = df[df['jumlah_kata'] == 1].copy()
print(f"Data 1 kata yang dihapus: {len(df_missing)}")

# Hapus data 1 kata
df_clean = df[df['jumlah_kata'] > 1].copy()

# Hapus duplikat
sebelum = len(df_clean)
df_clean = df_clean.drop_duplicates(subset='Sentimen_clean')
print(f"Duplikat dihapus: {sebelum - len(df_clean)}")
print(f"Jumlah data bersih: {len(df_clean)}")
```

```
Data 1 kata yang dihapus: 188
Duplikat dihapus: 0
Jumlah data bersih: 312
```

Dilanjutkan cleaning untuk data" yang hanya berisi 1 kata, disini juga kami menghapus karena data 1 kata tidak memliki konteks dan dianggap sebagai NULL, ini dilakukan agar bisa melanjutkan ke proses selanjutnya, terlihat di output bahwa 188 data 1 kata sudah terhapus dan tersisa 312 data yang clean

PREPROCESSING DATA

```python
# Kata kunci yang dalam konteks cyberbullying
kata_kunci = ['anjing', 'babi', 'goblok', 'mati', 'tolol']

# Aturan labeling sederhana berbasis konteks
konteks_non_bully = [
    'pelihara', 'poodle', 'golden', 'retriever', 'labrador', 'herder',
    'chihuahua', 'vaksin', 'dokter hewan', 'daging', 'masak', 'guling',
    'ternak', 'peternak', 'kandang', 'hutan', 'liar', 'bali', 'adat',
    'film', 'cerita', 'pasar', 'harga', 'budget', 'konservasi',
    'penelitian', 'dokumenter', 'trainer', 'shelter', 'sterilisasi',
    'komunitas', 'mitologi', 'petani', 'kebun', 'sawah', 'pedalaman',
    'jantan', 'betina', 'anak', 'indukan', 'bobot', 'subsidi', 'lomba',
    'border', 'collie', 'dachshund', 'chow', 'greyhound', 'malamute',
    'melahirkan', 'ras', 'bulu', 'gonggong'
]

def label_sentimen(text):
    text_lower = str(text).lower()

    # Cek apakah mengandung kata kunci bully
    ada_kata_kunci = any(k in text_lower for k in kata_kunci)

    if not ada_kata_kunci:
        return 'non-cyberbully'

    # Kalau ada kata kunci, cek konteks
    ada_konteks_non = any(k in text_lower for k in konteks_non_bully)

    if ada_konteks_non:
        return 'non-cyberbully'
    else:
        return 'cyberbully'

df_clean['Label'] = df_clean['Sentimen_clean'].apply(label_sentimen)

print("=== DISTRIBUSI LABEL ===")
print(df_clean['Label'].value_counts())
print(f"\nPersentase cyberbully : {(df_clean['Label']=='cyberbully').mean()*100:.1f}%")
print(f"Persentase non-bully  : {(df_clean['Label']=='non-cyberbully').mean()*100:.1f}%")
```

```
=== DISTRIBUSI LABEL ===
Label
cyberbully        215
non-cyberbully     97
Name: count, dtype: int64

Persentase cyberbully : 68.9%
Persentase non-bully  : 31.1%
```

Dilanjutkan dengan labelling, disini kami memisah antara data yang menunjukkan cyberbullying dan data netral (non-cyberbullying), dan output menunjukkan terdapat 215 data sentimen yang merupakan cyberbullying dan 97 data sentimen yang merupakan non-cyberbullying

MEMBUAT BUCKET

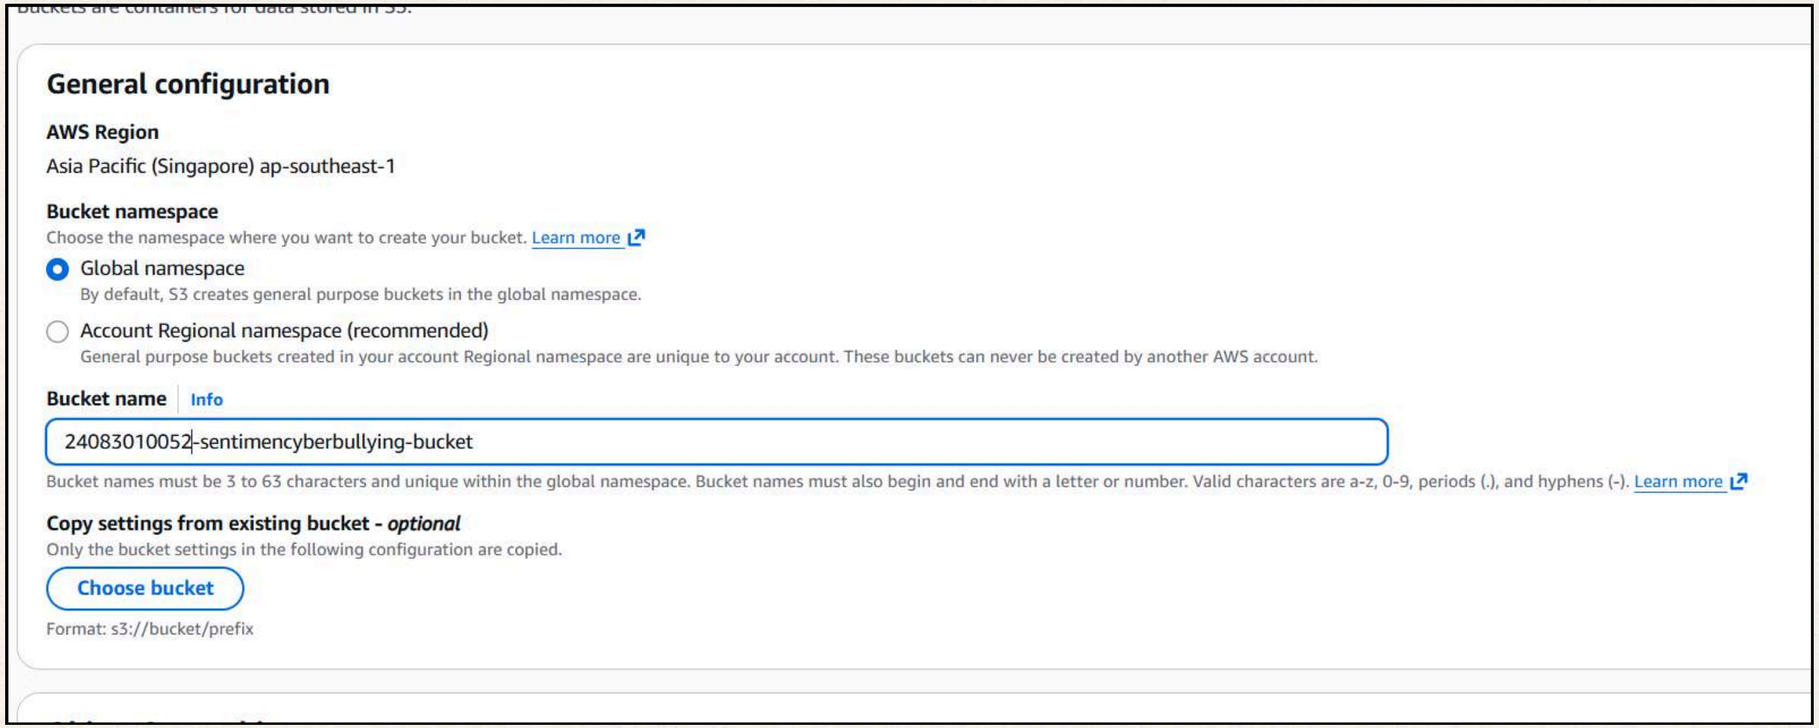

Membuka AWS S3 kemudian pilih menu create bucker untuk membuat bucket, kemudian masukkan nama bucket sesuai dengan ketentuan laporan, disini saya memeberikan bucket dengan nama “24083010052-sentimencyberbullying-bucket”.

MEMBUAT BUCKET

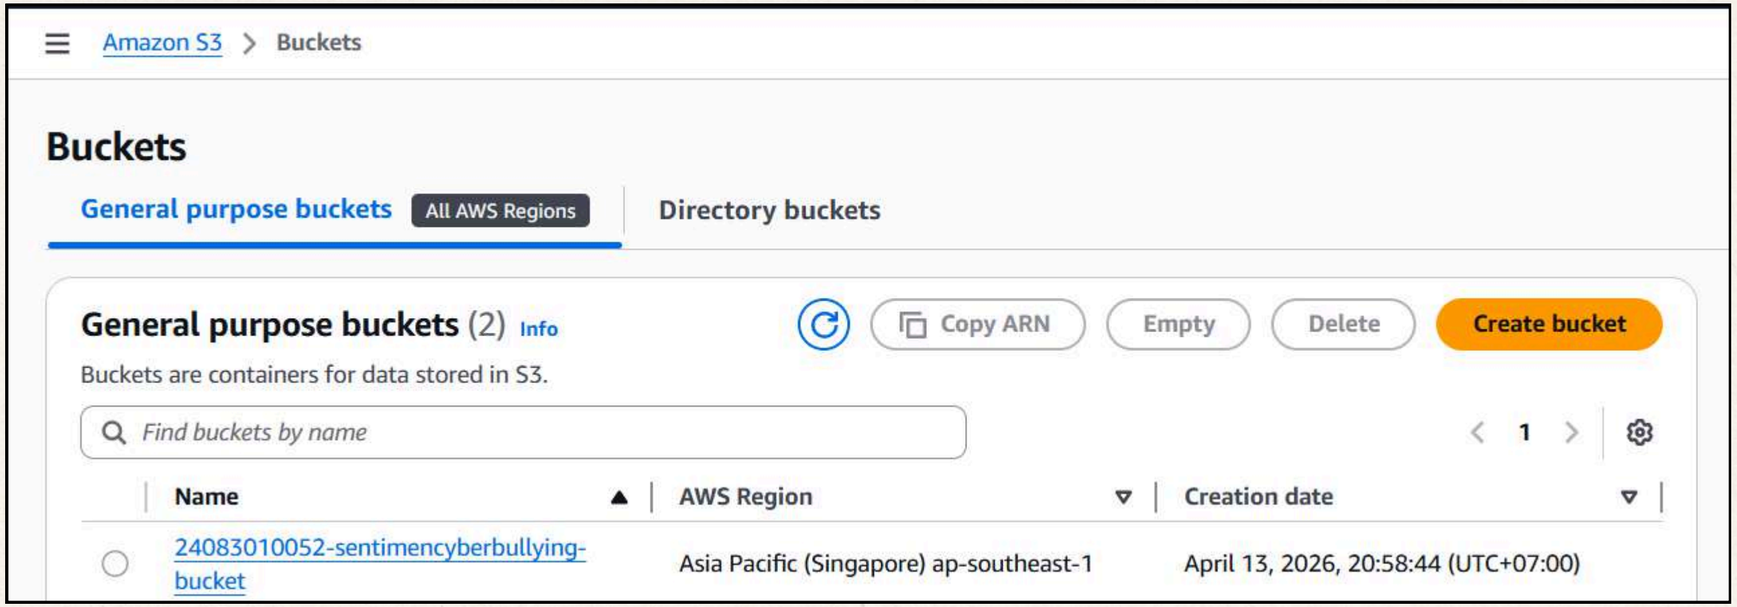

Bucket berhasil dibuat ditandai dengan nama bucket yang muncul (available) pada menu utama bucket

VERSIONING

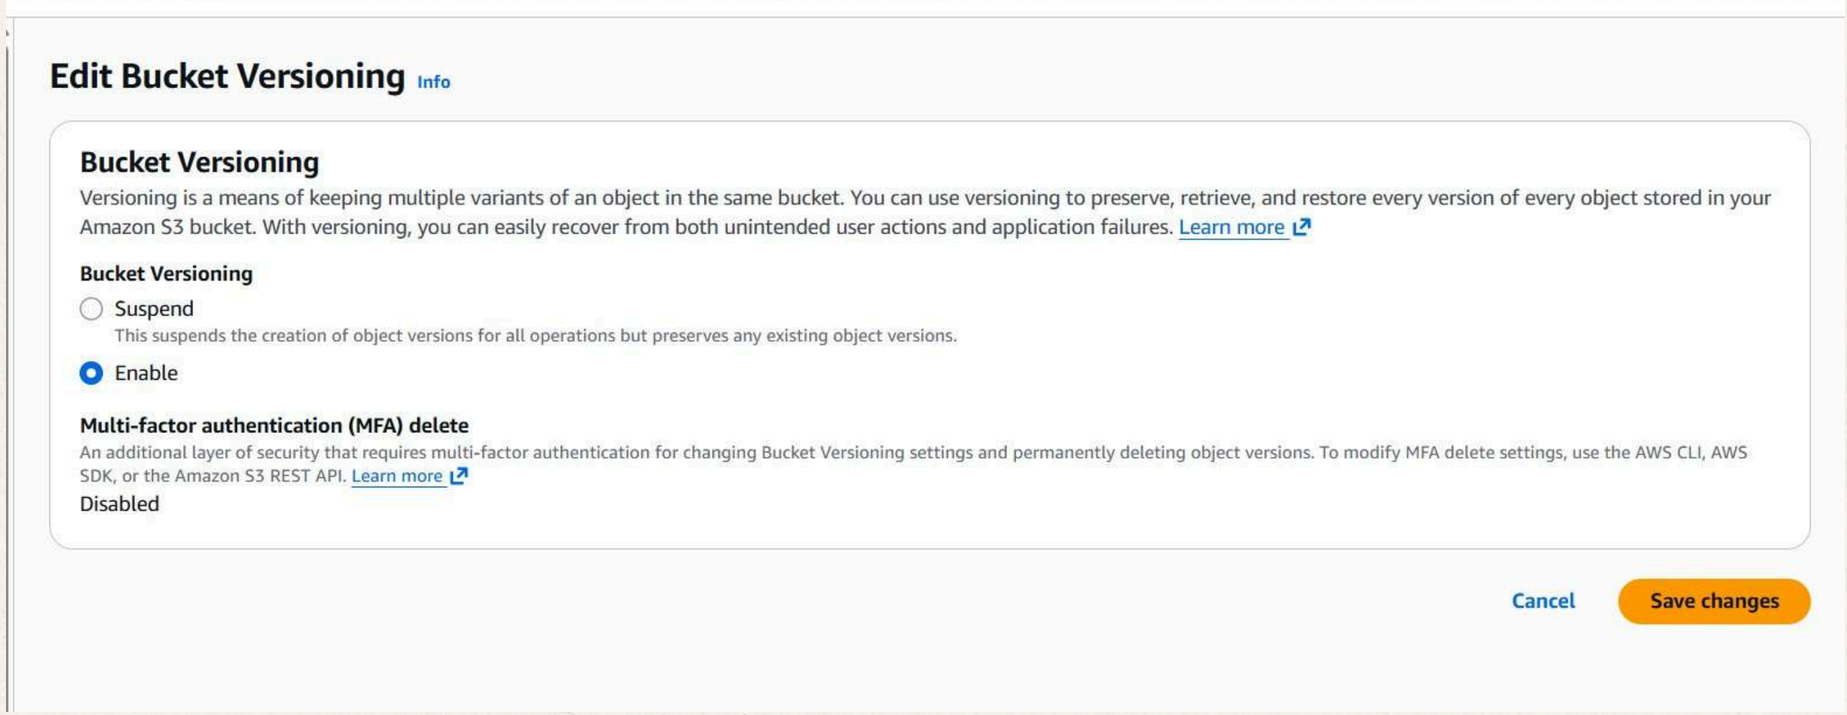

Fitur versioning pada S3 memungkinkan bucket menyimpan banyak versi dari satu objek yang sama, sehingga setiap unggahan ulang file tidak akan menghapus versi sebelumnya. Dengan mengaktifkan opsi Enable, bucket dapat digunakan untuk memulihkan data dari kesalahan pengguna atau aplikasi, sementara opsi Suspend hanya menghentikan pembuatan versi baru tanpa menghapus versi yang sudah ada.

MEMBUAT FOLDER RAW DAN PROCESSED

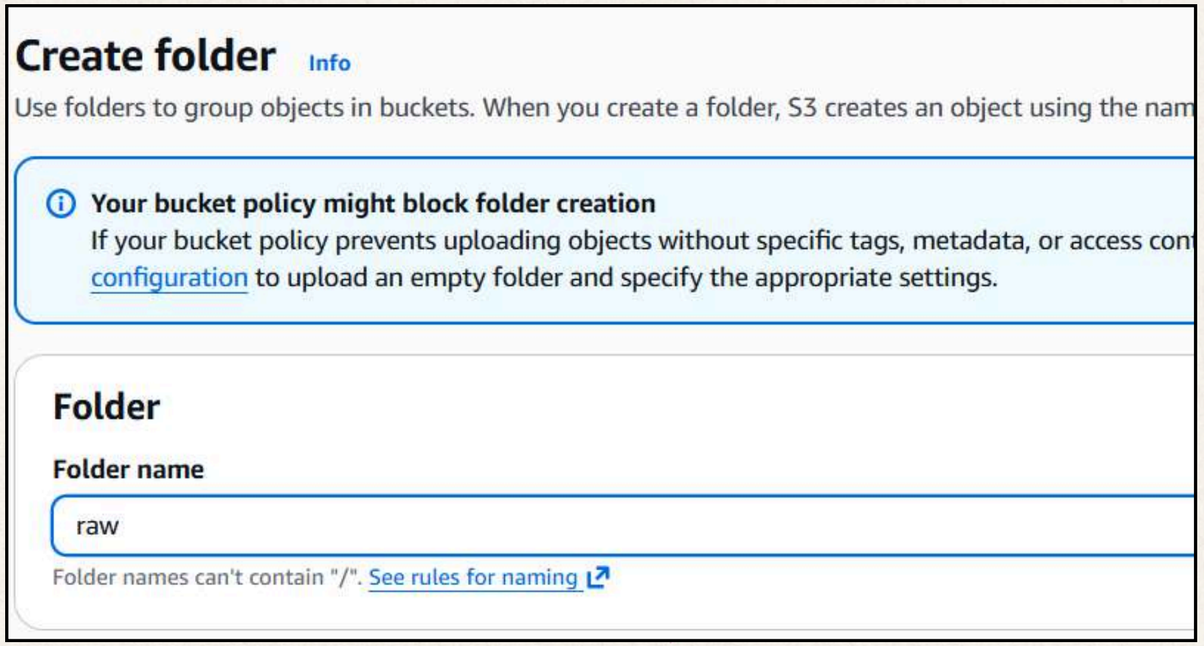

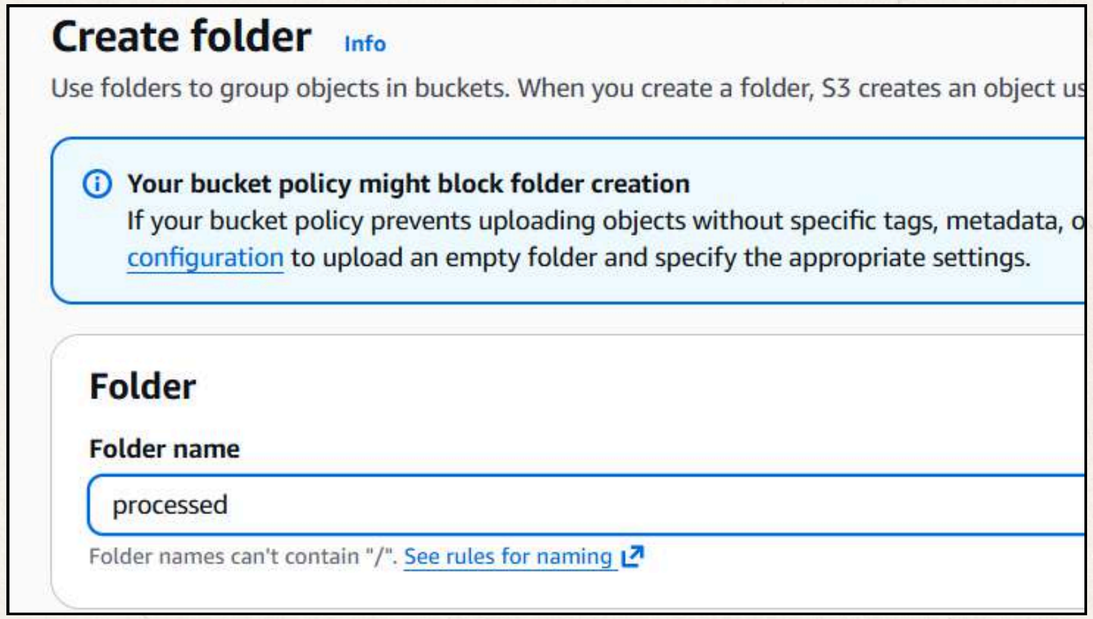

Pencet bucket yang telah sebelumnya untuk membuat folder /raw dan /processed untuk menyimpan data csv sebelum dan setelah progress.

FOLDER TELAH DI MUAT DI BUCKET

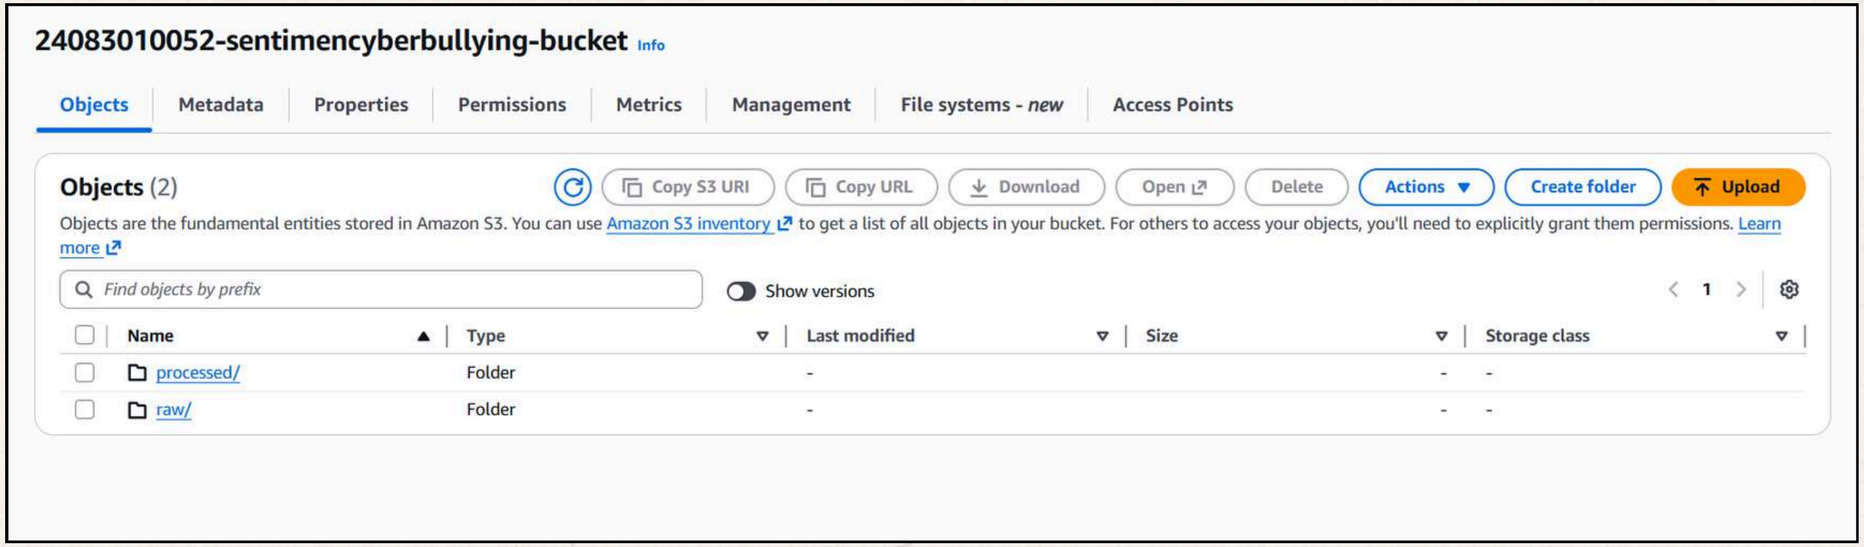

File raw dan processed berhasil dibuat ditandai dengan munculnya kedua folder tersebut pada menu utama didalam bucket nya.

UPLOAD CSV RAW DAN PROCESSED

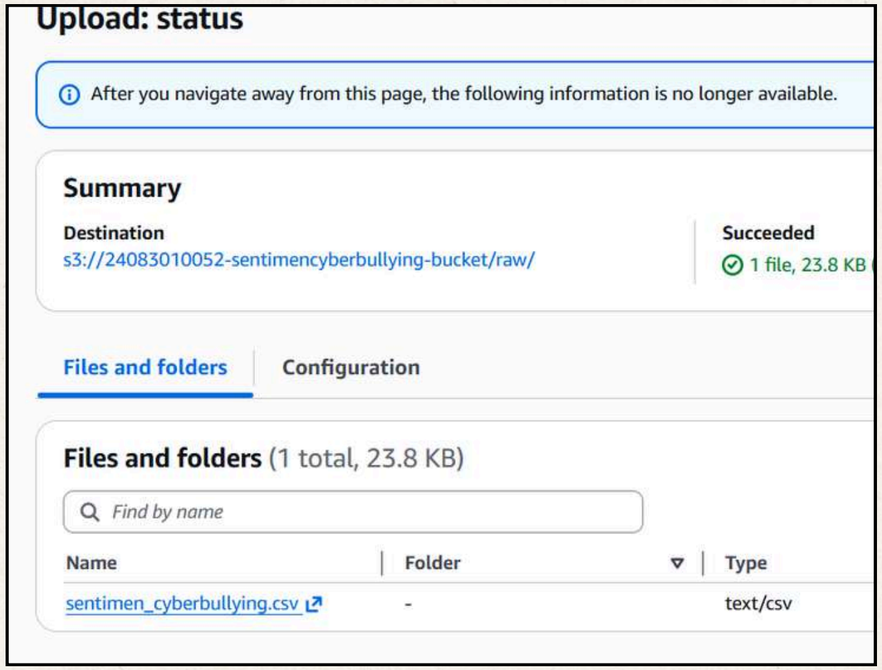

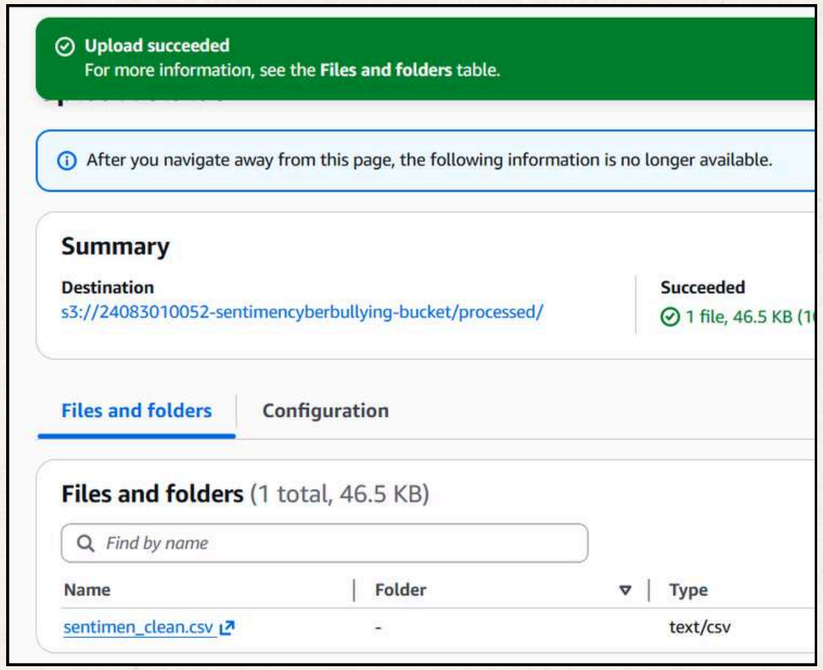

Memasukkan data raw hasil scrapping twitter kedalam folder /raw, sementara itu untuk hasil scrapping twitter yang telah di preprocessed dengan nama setimen_clean.csv kedalam folder /processed

MEMBUAT DOMAIN DI SAGEMAKER

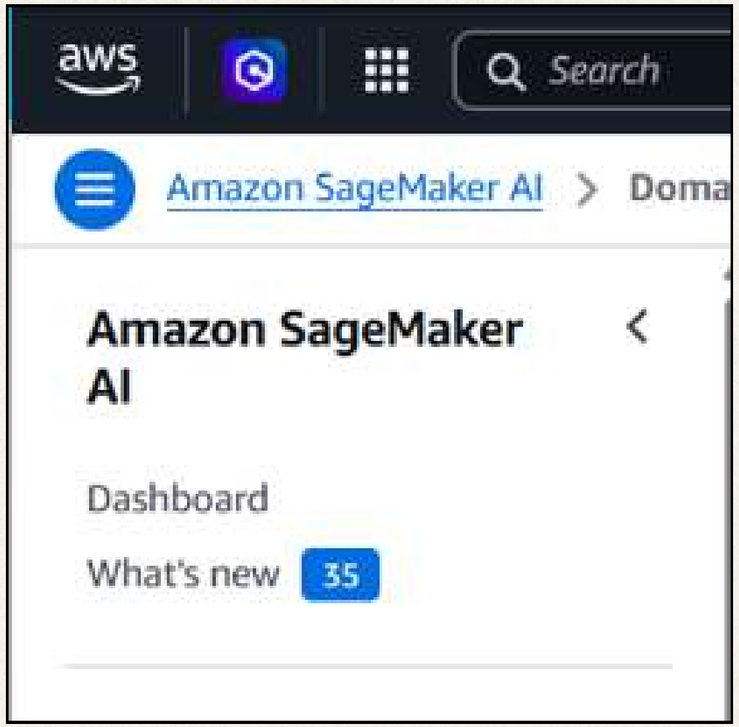

Kami memilih Amazon SageMaker AI karena proses aktivasi SageMaker Studio Lab memerlukan persetujuan akun yang memakan waktu lama, sementara EC2 membutuhkan konfigurasi manual yang merepotkan. Dengan SageMaker AI, kami langsung mendapatkan lingkungan JupyterLab terintegrasi dengan S3 tanpa perlu menunggu approval atau setup server.

MEMILIH POLICIES YANG DIBUTUHKAN

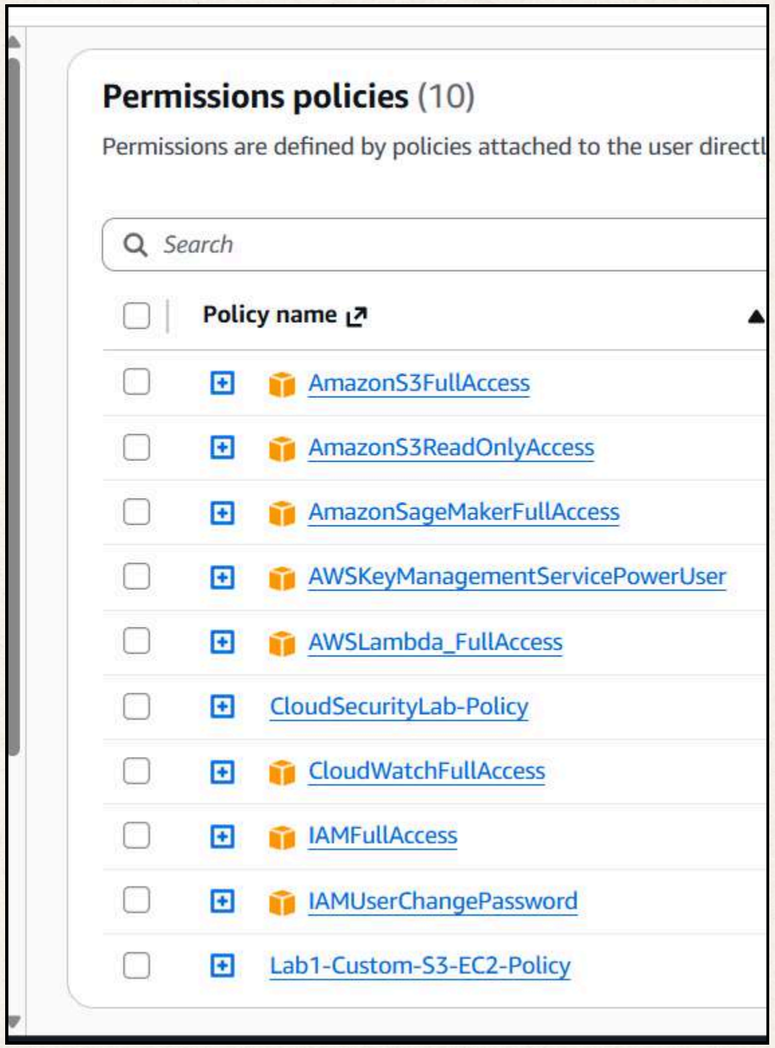

Kami memilih kebijakan seperti AmazonS3FullAccess, AmazonSageMakerFullAccess, dan IAMFullAccess agar IAM user dapat membuat bucket S3, mengunggah data, serta membuat dan mengelola domain SageMaker dan role yang diperlukan. Kebijakan tambahan seperti CloudWatchFullAccess dan AWSKeyManagementServicePowerUser kami sertakan untuk mendukung logging dan enkripsi data, sehingga seluruh pipeline berjalan lancar tanpa kendala izin.

MEMBUAT ROLE

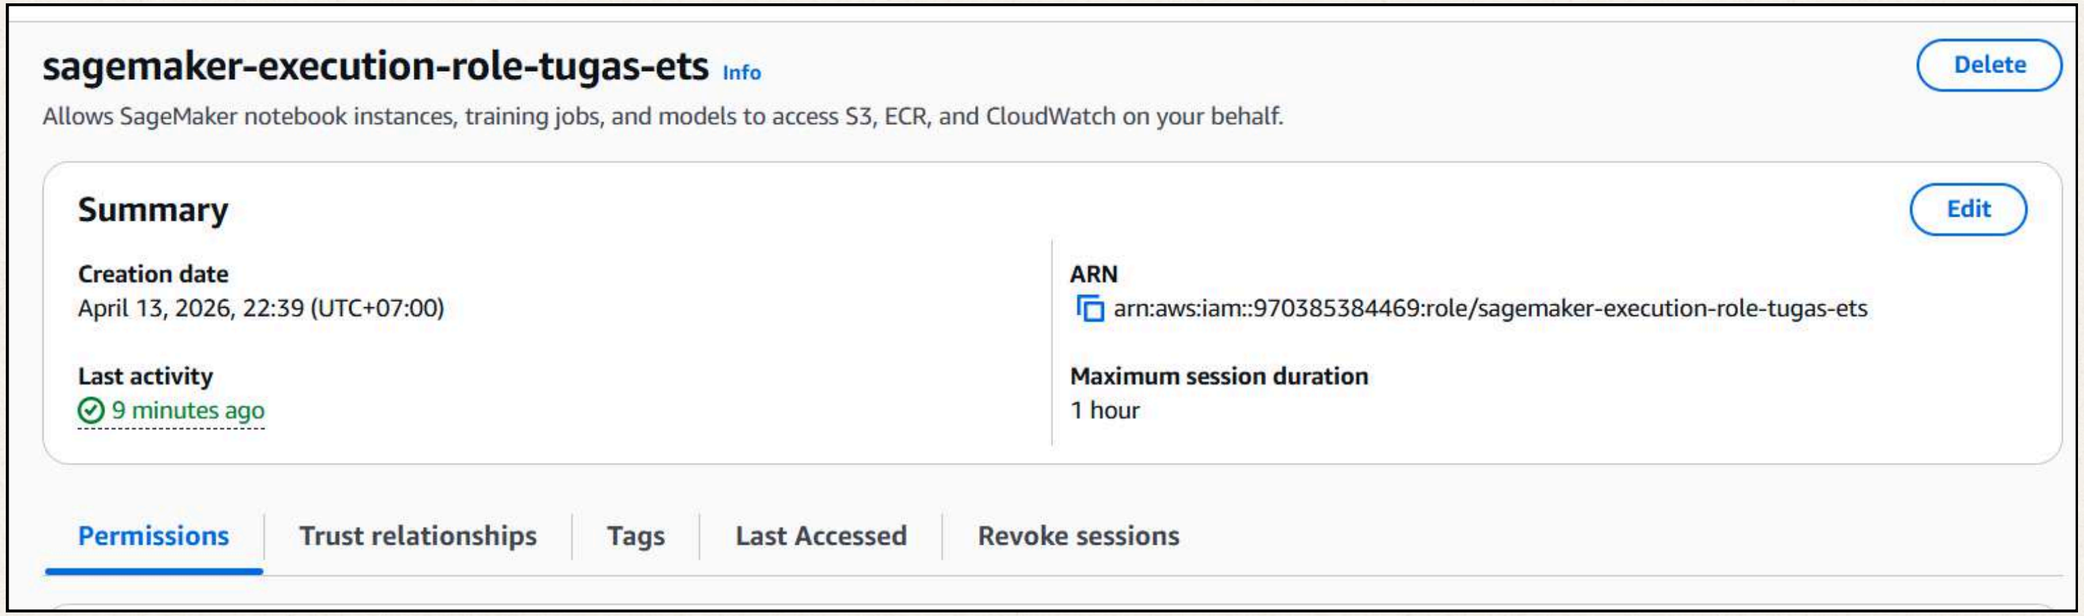

Role sagemaker-execution-role-tugas-ets memberikan izin kepada layanan AWS SageMaker untuk mengakses bucket S3 tempat data sentimen disimpan, sehingga notebook JupyterLab dapat membaca dan menulis file secara otomatis tanpa perlu menyimpan kunci akses. Dengan role ini, pipeline analisis sentimen berjalan aman dan terintegrasi penuh di cloud.

REVIEW DOMAIN SEBELUM CREATE

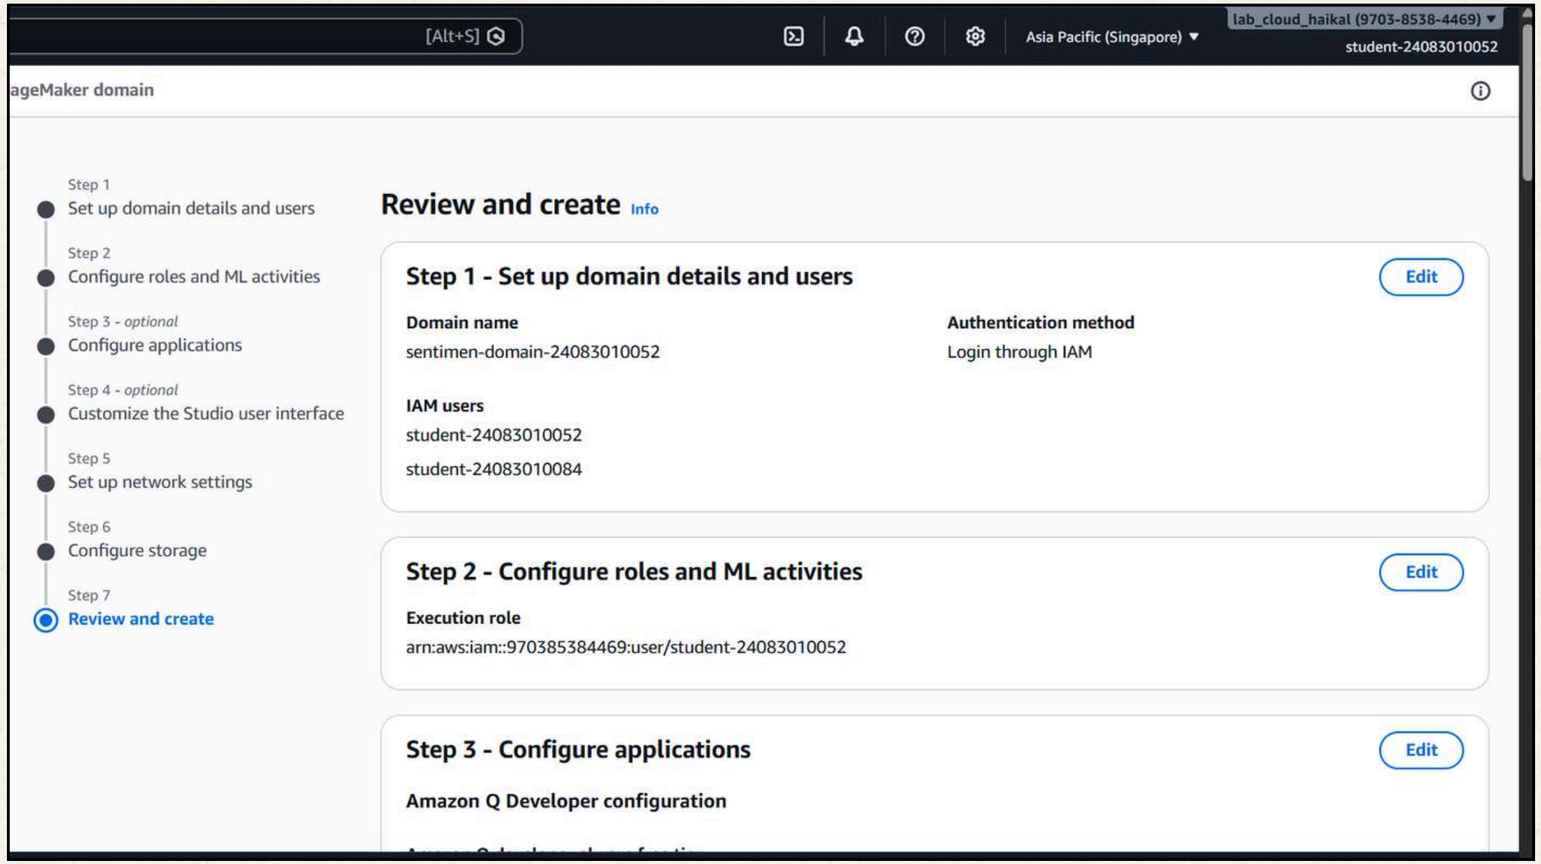

MENUNGGU SAGEMAKER DOMAIN DIBUAT

Preparing SageMaker domain. Do not close this browser tab.
We are configuring the resources needed by the domain. This is a one-time configuration and may take a few minutes.

sentimen-domain-24083010052

Domain details

Configure and manage the domain.

Domain settings | User profiles | Space management | App configurations | Environment | Resources

General settings

Name	Status	Domain ID
sentimen-domain-24083010052	Pending	d-2hfz4cipseby
Created	**Last modified**	**VPC**
Mon Apr 13 2026 22:53:17 GMT+0700 (Western Indonesia Time)	Mon Apr 13 2026 22:53:17 GMT+0700 (Western Indonesia Time)	vpc-01b05480afac0fbec

Domain rules

Manage rules

Visibility of instance and image resources for this domain

Rule type	Application type	Rule action	Resource
No domain rules			

DOMAIN SAGEMAKER TELAH DIBUAT

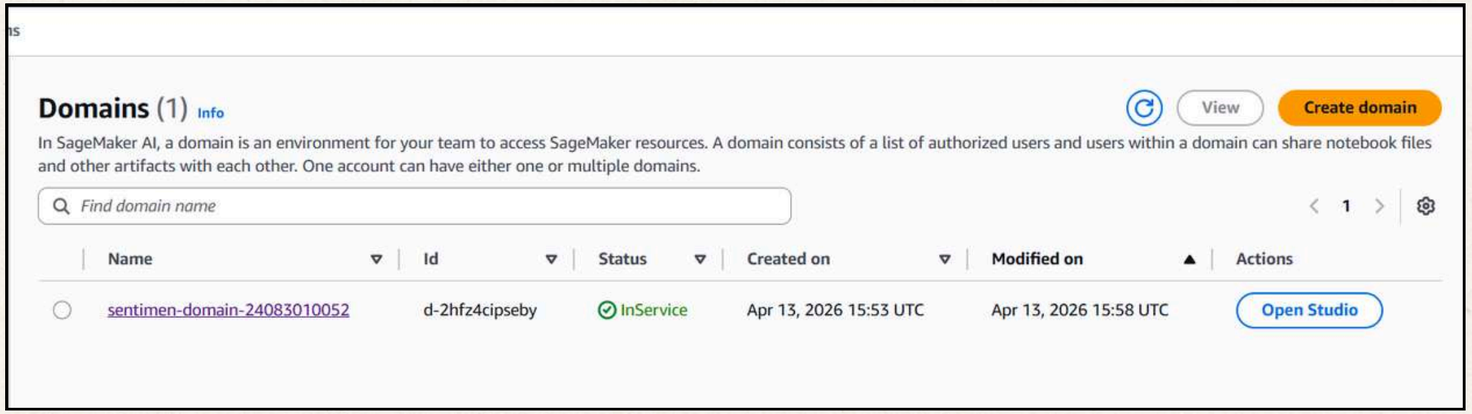

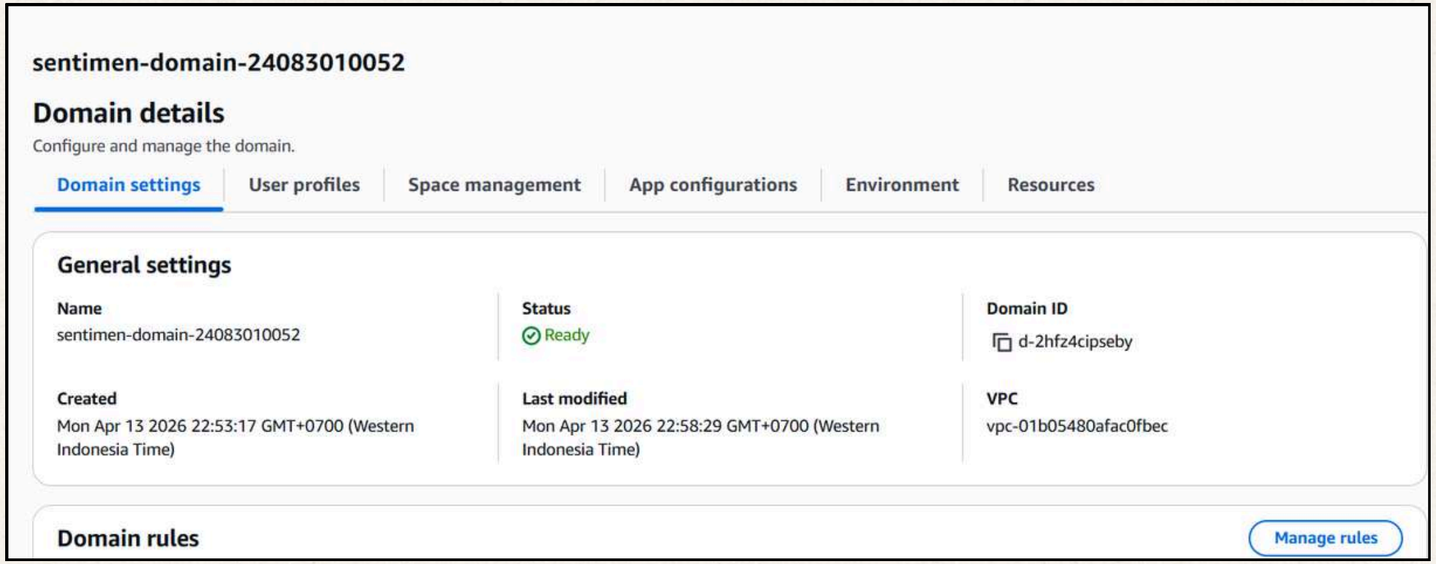

MEMBUAT FILE JUPYTER DI SAGEMAKER

Name	Modified on	Created on	Actions
student-24083010084	Apr 13, 2026 15:58 UTC	Apr 13, 2026 15:58 UTC	Open Studio
student-24083010052	Apr 13, 2026 15:58 UTC	Apr 13, 2026 15:58 UTC	Open Studio

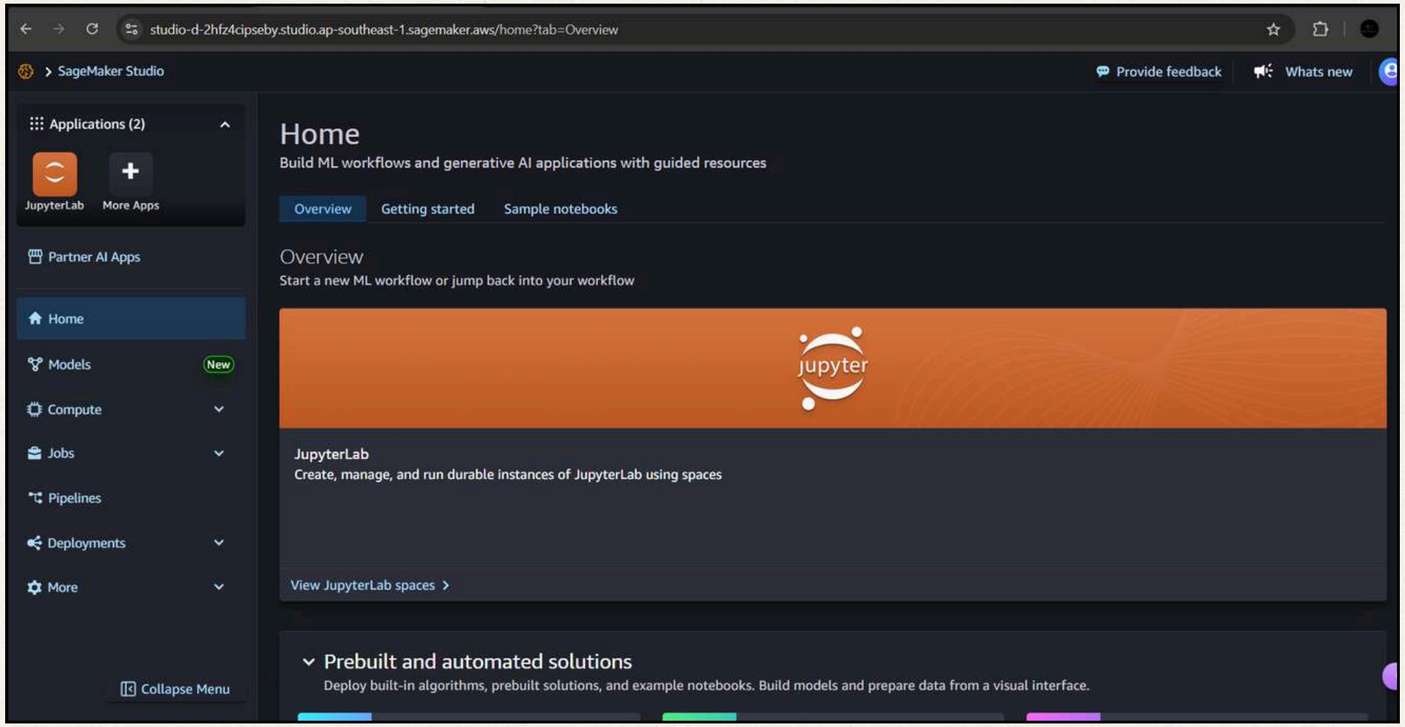

MENUNGGU SAGEMAKER DOMAIN DIBUAT

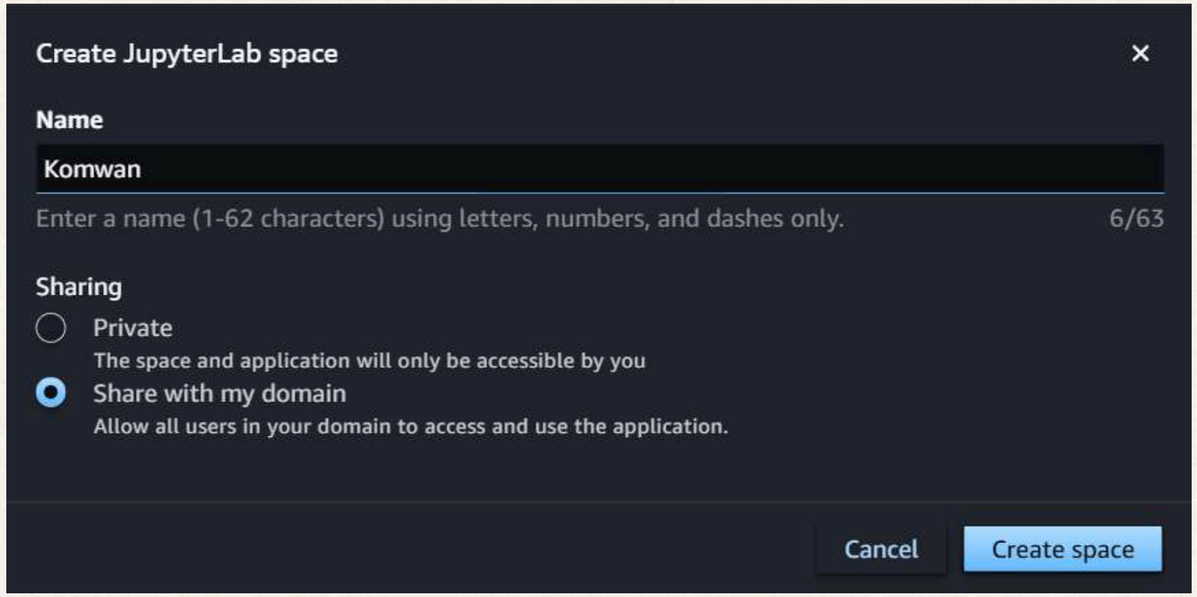

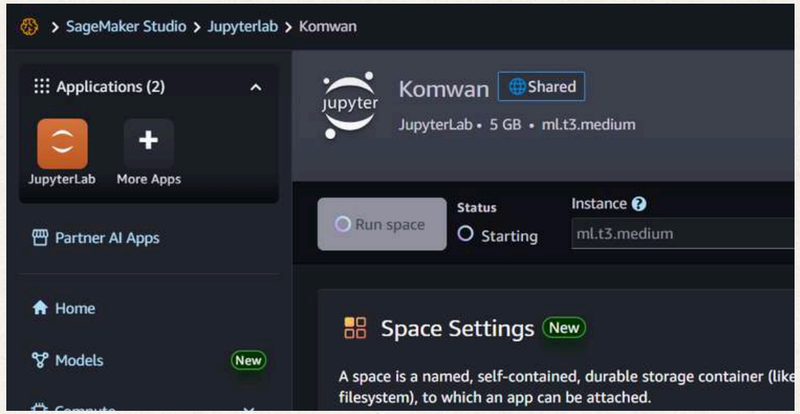

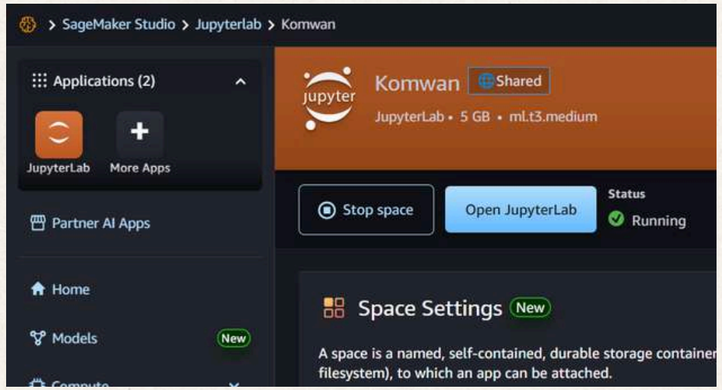

ANALISIS SAGEMAKER

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import re
import boto3
import matplotlib.gridspec as gridspec
import seaborn as sns
from sklearn.metrics import confusion_matrix, classification_report, accuracy_score
from sklearn.linear_model import LogisticRegression
from collections import Counter
from io import StringIO
from wordcloud import WordCloud
from sklearn.model_selection import train_test_split
from sklearn.naive_bayes import MultinomialNB
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.naive_bayes import MultinomialNB
```

Disini kami akan menganalisis data menggunakan Sagemaker dan run jupyter dari Sagemaker, dimulai dari import semua library yang dibutuhkan

ANALISIS SAGEMAKER

```python
import boto3
import pandas as pd
from io import StringIO

s3 = boto3.client('s3', region_name='ap-southeast-1')

bucket = '24083010052-sentimencyberbullying-bucket'
key = 'processed/sentimen_clean.csv'

obj = s3.get_object(Bucket=bucket, Key=key)
data = obj['Body'].read().decode('utf-8')

df_processed = pd.read_csv(StringIO(data))

df_processed.head()
```

	No	Sentimen	Sentimen_clean	Label
0	1	anjing poodle ku baru aja makan 3x sehari pada...	anjing poodle ku baru aja makan 3x sehari pada...	non-cyberbully
1	2	dasar goblok ngerjain tugas aja salah mulu men...	dasar goblok ngerjain tugas aja salah mulu men...	cyberbully
2	4	harga daging babi di pasar naik lagi bikin bud...	harga daging babi di pasar naik lagi bikin bud...	non-cyberbully
3	5	mati aja lo sekalian ga ada yang butuh lo di d...	mati aja lo sekalian ga ada yang butuh lo di d...	cyberbully
4	6	orang itu kelakuannya tolol banget masa passwo...	orang itu kelakuannya tolol banget masa passwo...	cyberbully

Dilanjutkan dengan mangambil data yang tadi sudah diupluad di Bucket S3 IAM AWS menggunakan library Boto3, dengan memasang nama bucket dan nama file sebagai keynya, setelah itu didefinisan sebagai df_processed dan ditampilkan 5 data teratasnya menggunakan fungsi df_processed.head()

ANALISIS SAGEMAKER

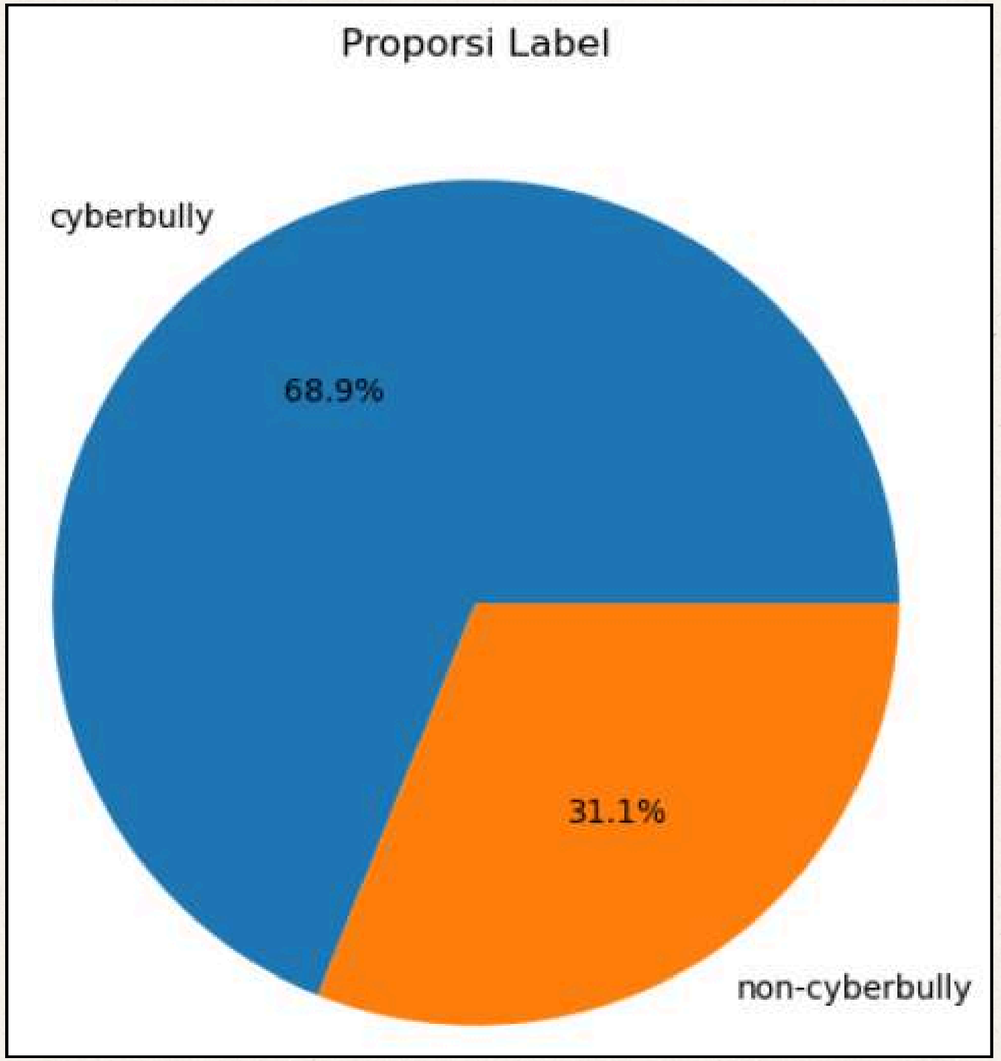


```
# Pie Chart Distribusi Label

df_processed['Label'].value_counts().plot(
    kind='pie',
    autopct='%1.1f%%',
    figsize=(6,6)
)
plt.title('Proporsi Label')
plt.ylabel('')
plt.show()
```

Dari 312 data bersih hasil preprocessing, pie chart menunjukkan bahwa 68,9% (215 data) berlabel cyberbully dan 31,1% (97 data) berlabel non-cyberbully. Ketidakseimbangan kelas ini terjadi karena data dikumpulkan berdasarkan kata kunci yang memang erat kaitannya dengan konten negatif, sehingga wajar jika proporsi cyberbully lebih dominan.

ANALISIS SAGEMAKER

```python
# WordCloud
wc = WordCloud(
    width=900,
    height=450,
    background_color='white',
    colormap='Reds'
).generate(final_text)

plt.figure(figsize=(12,6))
plt.imshow(wc, interpolation='bilinear')
plt.axis('off')
plt.title("WordCloud (Filtered + Priority Boost)")
plt.show()
```

WordCloud memvisualisasikan kata-kata yang paling sering muncul dalam dataset, di mana kata "anjing", "babi", "goblok", "tolol", dan "mati" mendominasi dengan ukuran paling besar sesuai priority boost yang diberikan. Selain kata kunci utama, kata-kata pendukung seperti "banget", "dasar", "orang", dan "ga" juga cukup sering muncul, mencerminkan pola kalimat cyberbullying yang umum digunakan di media sosial. Visualisasi ini memperkuat bahwa kelima kata kunci tersebut memang menjadi inti dari konten cyberbullying dalam dataset ini.

ANALISIS SAGEMAKER

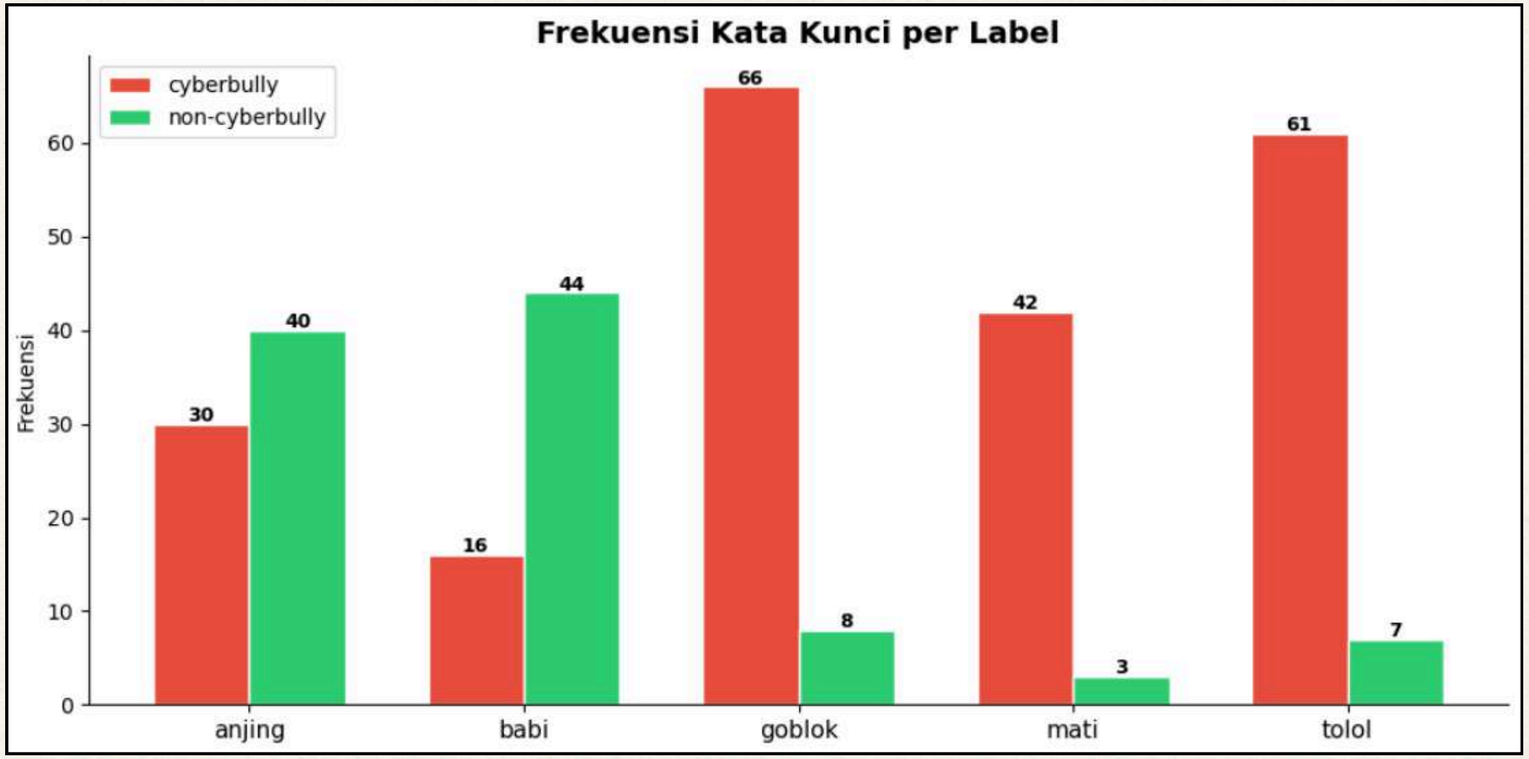


```python
# Frekuensi Kata Kunci

kata_kunci = ['anjing', 'babi', 'goblok', 'mati', 'tolol']

def hitung_frekuensi(df, label):
    teks = ' '.join(df[df['Label'] == label]['Sentimen_clean'].astype(str))
    return [teks.split().count(k) for k in kata_kunci]

freq_bully    = hitung_frekuensi(df_processed, 'cyberbully')
freq_nonbully = hitung_frekuensi(df_processed, 'non-cyberbully')

fig, ax = plt.subplots(figsize=(10, 5))
x = np.arange(len(kata_kunci))
w = 0.35
b1 = ax.bar(x - w/2, freq_bully,    w, label='cyberbully',     color='#E74C3C', edgecolor='white')
b2 = ax.bar(x + w/2, freq_nonbully, w, label='non-cyberbully', color='#2ECC71', edgecolor='white')
for bar in list(b1) + list(b2):
    h = bar.get_height()
    ax.text(bar.get_x() + bar.get_width()/2, h + 0.3,
            str(h), ha='center', fontsize=9, fontweight='bold')
ax.set_title('Frekuensi Kata Kunci per Label', fontsize=14, fontweight='bold')
ax.set_ylabel('Frekuensi')
ax.set_xticks(x); ax.set_xticklabels(kata_kunci, fontsize=11)
ax.legend(); ax.spines[['top', 'right']].set_visible(False)

plt.tight_layout()
plt.savefig('viz_2_frekuensi.png', dpi=150, bbox_inches='tight')
plt.show()
```

Grafik ini menunjukkan frekuensi kemunculan kelima kata kunci pada masing-masing label, di mana kata "goblok" (66) dan "tolol" (61) paling dominan muncul pada konten cyberbully, sementara kata "babi" (44) dan "anjing" (40) justru lebih sering muncul pada konten non-cyberbully karena banyak digunakan dalam konteks netral seperti peternakan dan hewan peliharaan. Kata "mati" dan "goblok" hampir tidak muncul di konten non-cyberbully (masing-masing hanya 3 dan 8), menjadikannya indikator paling kuat untuk mendeteksi cyberbullying dalam dataset ini.

ANALISIS SAGEMAKER

```python
X = df_processed['Sentimen_clean']
y = df_processed['Label']

X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.2,
    random_state=42,
    stratify=y
)

print(f"X_train: {len(X_train)} | X_test: {len(X_test)}")
```

```
X_train: 249 | X_test: 63
```

```python
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.naive_bayes import MultinomialNB

# Ubah teks ke angka dengan TF-IDF
vectorizer = TfidfVectorizer()
X_train_tfidf = vectorizer.fit_transform(X_train)
X_test_tfidf  = vectorizer.transform(X_test)

# Barulah fit model
nb_model = MultinomialNB()
nb_model.fit(X_train_tfidf, y_train)

print("✅ Model berhasil dilatih!")
```

Data dibagi menjadi 249 data training (80%) dan 63 data testing (20%) menggunakan stratified split agar proporsi label tetap seimbang di kedua set. Teks kemudian diubah menjadi representasi numerik menggunakan TF-IDF Vectorizer, yang mengukur seberapa penting suatu kata dalam dokumen relatif terhadap seluruh dataset. Model Naive Bayes lalu dilatih menggunakan data training yang sudah divektorisasi dan berhasil dilatih tanpa error.

ANALISIS SAGEMAKER

```
=== Naive Bayes ===
Accuracy: 0.9047619047619048
                precision    recall  f1-score   support

    cyberbully       0.88      1.00      0.93        43
non-cyberbully       1.00      0.70      0.82        20

      accuracy                           0.90        63
     macro avg       0.94      0.85      0.88        63
  weighted avg       0.92      0.90      0.90        63
```

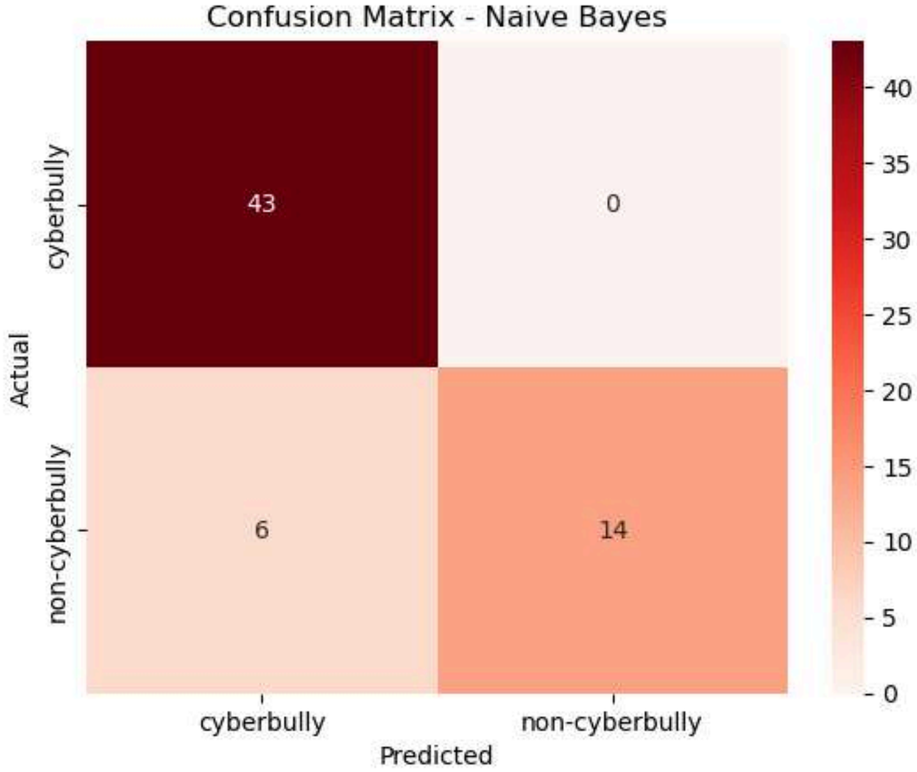


```python
# Naive Bayes

y_pred_nb = nb_model.predict(X_test_tfidf)  # bukan X_test

print("=== Naive Bayes ===")
print("Accuracy:", accuracy_score(y_test, y_pred_nb))
print(classification_report(y_test, y_pred_nb))

cm_nb = confusion_matrix(y_test, y_pred_nb)
sns.heatmap(cm_nb, annot=True, fmt='d', cmap='Reds',
            xticklabels=['cyberbully', 'non-cyberbully'],
            yticklabels=['cyberbully', 'non-cyberbully'])
plt.title("Confusion Matrix - Naive Bayes")
plt.xlabel("Predicted")
plt.ylabel("Actual")
plt.show()
```

Model Naive Bayes mencapai akurasi 90,5% dengan performa sangat baik pada kelas cyberbully (precision 88%, recall 100%), artinya model berhasil mendeteksi seluruh 43 data cyberbully tanpa ada yang terlewat. Namun pada kelas non-cyberbully, terdapat 6 data yang salah diprediksi sebagai cyberbully (false positive), sehingga recall-nya hanya 70% – kemungkinan karena kalimat non-cyberbully yang mengandung kata kunci tetap terbaca negatif oleh model. Secara keseluruhan model ini sudah cukup andal, terutama untuk mendeteksi konten cyberbullying.

ANALISIS SAGEMAKER

```
=== Logistic Regression ===
Accuracy: 0.9365079365079365
                precision    recall  f1-score   support

    cyberbully       0.91      1.00      0.96        43
non-cyberbully       1.00      0.80      0.89        20

      accuracy                           0.94        63
     macro avg       0.96      0.90      0.92        63
  weighted avg       0.94      0.94      0.93        63
```

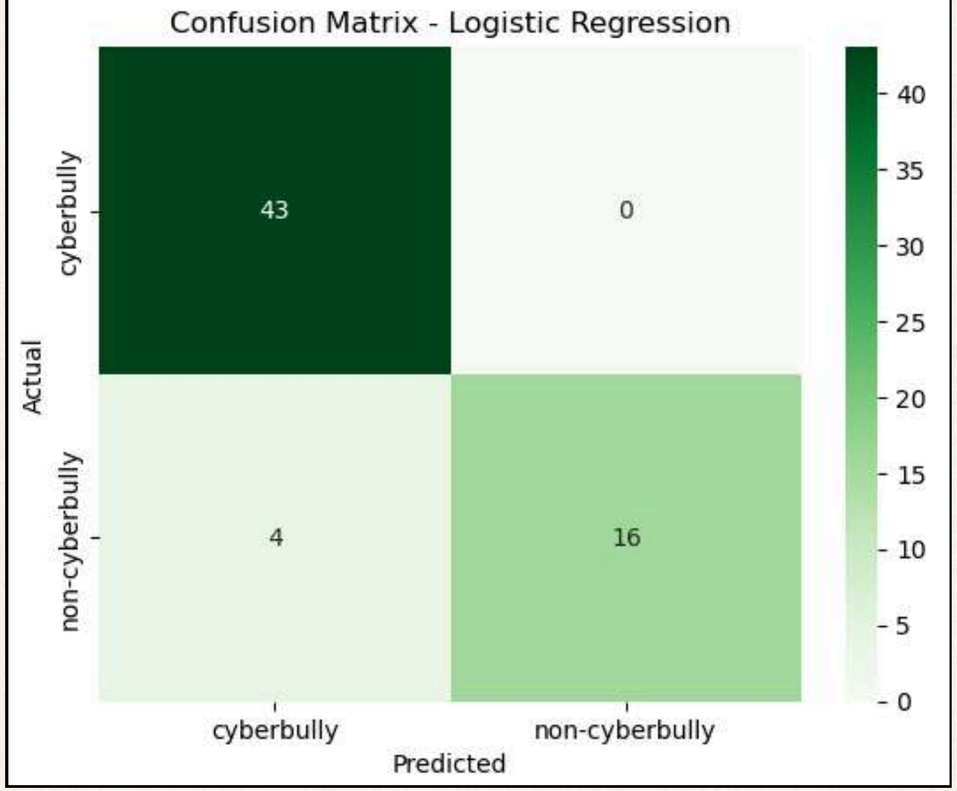


```python
# Logistic Regression

lr_model = LogisticRegression(max_iter=1000)
lr_model.fit(X_train_tfidf, y_train)        # bukan X_train
y_pred_lr = lr_model.predict(X_test_tfidf)  # bukan X_test

print("=== Logistic Regression ===")
print("Accuracy:", accuracy_score(y_test, y_pred_lr))
print(classification_report(y_test, y_pred_lr))

cm_lr = confusion_matrix(y_test, y_pred_lr)
sns.heatmap(cm_lr, annot=True, fmt='d', cmap='Greens',
            xticklabels=['cyberbully', 'non-cyberbully'],
            yticklabels=['cyberbully', 'non-cyberbully'])
plt.title("Confusion Matrix - Logistic Regression")
plt.xlabel("Predicted")
plt.ylabel("Actual")
plt.show()
```

Model Logistic Regression mencapai akurasi 93,7%, lebih tinggi dibanding Naive Bayes, dengan seluruh 43 data cyberbully berhasil diprediksi benar (recall 100%) dan hanya 4 data non-cyberbully yang salah diklasifikasikan – lebih baik dari Naive Bayes yang salah pada 6 data. Peningkatan ini terlihat pada kelas non-cyberbully dengan recall naik dari 70% menjadi 80% dan precision sempurna 100%, menunjukkan bahwa Logistic Regression lebih mampu memahami konteks kalimat yang mengandung kata kunci namun bukan cyberbullying.

ANALISIS SAGEMAKER

```python
# Perbandingan

print("=== Perbandingan Akurasi ===")
print(f"Naive Bayes        : {accuracy_score(y_test, y_pred_nb):.4f}")
print(f"Logistic Regression: {accuracy_score(y_test, y_pred_lr):.4f}")
```

```
=== Perbandingan Akurasi ===
Naive Bayes        : 0.9048
Logistic Regression: 0.9365
```

Berdasarkan perbandingan kedua model, Logistic Regression (93,65%) unggul atas Naive Bayes (90,48%) dengan selisih sekitar 3,2%. Logistic Regression terbukti lebih optimal untuk dataset ini karena lebih baik dalam menangani konteks kalimat yang ambigu, sehingga menjadi model yang direkomendasikan untuk klasifikasi sentimen cyberbullying pada pipeline ini.

Kesimpulan

Proyek ini membangun end-to-end pipeline analisis sentimen cyberbullying berbasis AWS, dimulai dari pengumpulan 500 data sentimen berbahasa Indonesia yang disimpan di AWS S3 dengan struktur raw/processed dan fitur versioning. Data diproses melalui SageMaker menggunakan boto3, menghasilkan 312 data bersih setelah penghapusan missing value dan pembersihan teks, kemudian dilabeli menjadi dua kelas: cyberbully (68,9%) dan non-cyberbully (31,1%). Dari dua model yang diuji, Logistic Regression dipilih sebagai model final dengan akurasi tertinggi 93,65%, mengungguli Naive Bayes (90,48%), dan terbukti lebih andal dalam mendeteksi konteks kalimat yang ambigu.

Video Demo

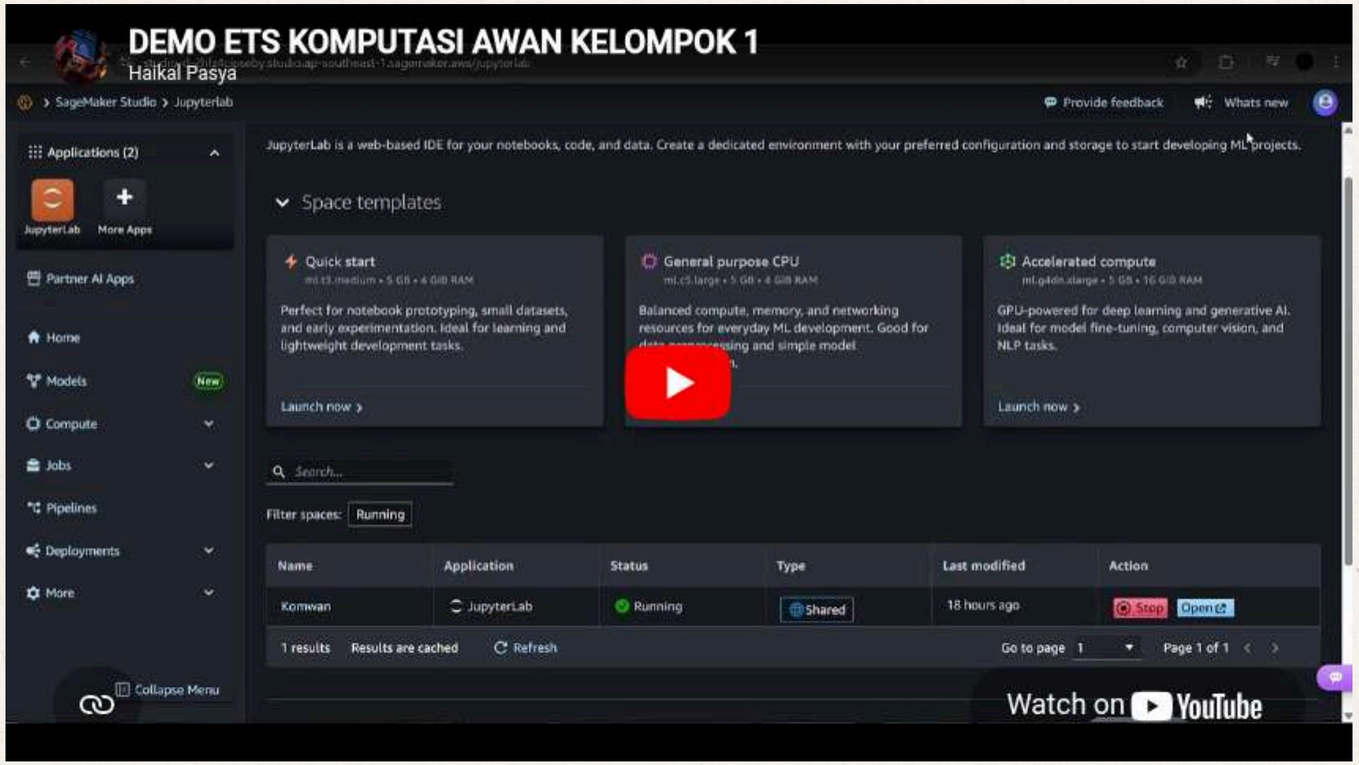

https://youtu.be/AlfV4NeG_1U

Video Presentasi

https://drive.google.com/file/d/1WlzafPk3bd9UjWTdhQtgbFRUAA8XzJ-p/view?usp=sharing

Link Repo Github

https://github.com/haipsy/Tugas-ets-komputasi-awan.git

Tabel Pembagian

Yogi (020)	Asruz (084)	Haikal (052)
Membuat diagram	Data Collecting	IAM User dan Role
Membuat PPT	Prepprocessing	Membuat Policy
Membuat laporan	Analisis Dengan Sagemaker	Membuat Storage (S3)
	Visualisasi	Membuat domain dan seluruh pipeline AWS
	Memebuat Laporan	Membuat Laporan
	Membuat PPT	Membuat PPT

Thank you

APAKAH TEMEN-TEMEN, MINASAN, ALL OF YOU, NJENENGAN SEDOYO ADA PERTANYAAN?